

Cuadro Comparativo / Matriz de Costos

Ecosistema IA — Screening de Candidatos

Justificación de modelos por tarea, estrategias de optimización y ahorro estimado

Autor: Iván Santos · Septiembre 2026 · Curso Automatización con IA

Índice

(Actualizar el índice en Word: clic derecho → Actualizar campo → Toda la tabla)

1. Contexto y Criterios de Selección

El workflow Ecosistema IA - Screening de Candidatos utiliza dos agentes de inteligencia artificial con propósitos diferentes. La elección de modelo para cada uno se basa en tres criterios:

Complejidad de la tarea: ¿Requiere razonamiento complejo (comparar un CV contra una job description de 2000+ palabras) o clasificación simple (determinar severidad de un error)?

Tolerancia a la latencia: ¿El candidato espera una respuesta en tiempo real (formulario) o el procesamiento puede ser asincrónico (batch nocturno de postulaciones acumuladas)?

Volumen proyectado: ¿Cuántas ejecuciones mensuales se esperan? Un proceso de screening típico para una empresa mediana maneja 50-200 candidatos/mes. Los errores son una fracción de ese volumen.

2. Tabla de Precios por Modelo (Septiembre 2026)

Precios públicos de la API de OpenAI. Se incluyen solo los modelos relevantes para este tipo de workload (no se incluyen modelos de razonamiento o-series que no aplican a este caso de uso).

Modelo	Input /MTok	Output /MTok	Cached Input	Batch (−50%)	Contexto
GPT-4o mini	\$0.15	\$0.60	\$0.075 (−50%)	\$0.075 / \$0.30	128K tokens
GPT-4.1 Nano	\$0.10	\$0.40	\$0.025 (−75%)	\$0.05 / \$0.20	1M tokens
GPT-4.1 Mini	\$0.40	\$1.60	\$0.10 (−75%)	\$0.20 / \$0.80	1M tokens
GPT-5.4 Nano	\$0.20	\$1.25	\$0.02 (−90%)	\$0.10 / \$0.625	400K tokens
GPT-5.4 Mini	\$0.75	\$4.50	\$0.075 (−90%)	\$0.375 / \$2.25	400K tokens
GPT-5.4	\$2.50	\$15.00	\$0.25 (−90%)	\$1.25 / \$7.50	400K tokens
GPT-5.6 Luna	\$0.20	\$1.20	\$0.02 (−90%)	\$0.10 / \$0.60	1.05M tokens
GPT-5.6 Terra	\$2.00	\$12.00	\$0.20 (−90%)	\$1.00 / \$6.00	1.05M tokens

Fuente: openai.com/api/pricing (septiembre 2026). Batch API: descuento fijo del 50% en input y output para jobs asíncronos con ventana de 24 horas. Prompt Caching: descuento automático en tokens de input repetidos (system prompt estable).

3. Asignación de Modelo por Tarea

3.1 Tarea 1: Evaluación de Candidatos (IA principal)

Criterio	Detalle
Nodo n8n	IA - Evaluar Candidato (LangChain Agent)
Modelo elegido	GPT-4o mini (\$0.15 / \$0.60 por MTok)
Alternativa descartada	GPT-5.4 Mini (\$0.75 / \$4.50) — 5x más caro, mejora marginal para esta tarea
Complejidad	MEDIA-ALTA: leer CV anonimizado (~800-1500 tokens), compararlo con job description (~500-1000 tokens), producir score + análisis (4 oraciones, ~150 tokens output)
Structured Output	Sí: JSON con score (0-10) y análisis (string). GPT-4o mini soporta structured output nativo
Tool Use	Sí: consulta historial de postulaciones previas en Airtable (1 herramienta)
Contexto necesario	~3000-4000 tokens totales (system prompt + CV + job description + historial). Muy dentro de los 128K disponibles
Latencia aceptable	Sí: el candidato no espera respuesta inmediata, el procesamiento es post-formulario

Justificación

GPT-4o mini es el modelo óptimo para esta tarea porque ofrece el mejor ratio calidad/precio para tareas de clasificación y análisis de texto de complejidad media. Soporta structured output (JSON schema) y tool use, ambos requeridos por el agente. Su score en MMLU (82%) es suficiente para comparar un CV contra una job description y producir un puntaje coherente. Un modelo más potente como GPT-5.4 Mini mejoraría marginalmente la calidad del análisis pero a un costo 5x mayor en input y 7.5x mayor en output, sin justificación para el volumen típico del caso de uso.

3.2 Tarea 2: Triage de Errores (IA secundaria)

Criterio	Detalle
Nodo n8n	IA - Triage de Error (LangChain Agent)
Modelo elegido	GPT-4.1 Nano (\$0.10 / \$0.40 por MTok)
Alternativa descartada	GPT-4o mini (\$0.15 / \$0.60) — funciona pero es 50% más caro sin ventaja real para clasificación binaria
Complejidad	BAJA: leer un mensaje de error (~50-100 tokens), buscar errores similares en Airtable, clasificar severidad (baja/alta) y acción (registrar/escalar)
Structured Output	Sí: JSON con 5 campos (nodo, mensaje, severidad, acción, resumen)
Tool Use	Sí: consulta errores similares en tabla Errors de Airtable (1 herramienta)
Contexto necesario	~500-800 tokens totales. Mínimo
Frecuencia	BAJA: solo se ejecuta cuando hay un error en el pipeline. Estimado: 5-15 veces/mes

Justificación

GPT-4.1 Nano es el modelo más económico del mercado que soporta structured output y tool use. La tarea de triage es esencialmente una clasificación binaria (baja/alta) con un resumen breve. No requiere razonamiento complejo, y la frecuencia de ejecución es baja (solo en errores del pipeline). Usar un modelo más potente aquí sería desperdiciar presupuesto en una tarea que un modelo de clasificación resuelve con la misma calidad.

4. Simulación de Costos Mensuales

4.1 Supuestos del escenario

Variable	Valor	Nota
Candidatos/mes	100	Escenario base para empresa mediana
Tokens input por evaluación	3,500	System prompt (800) + CV anon. (1200) + Job Desc (800) + historial (700)
Tokens output por evaluación	200	JSON: score + análisis de 4 oraciones
Errores/mes	10	Estimado conservador (~10% de ejecuciones)
Tokens input por triage	600	System prompt (300) + error msg (100) + historial errores (200)
Tokens output por triage	150	JSON: 5 campos del triage
Cache hit rate (system prompt)	85%	El system prompt es idéntico en todas las ejecuciones

4.2 Costo mensual: Escenario Real (modelos elegidos)

Concepto	Cálculo	Costo
Evaluación — input (sin cache)	$100 \times 3,500 \times 15\% \text{ sin cache} = 52,500 \text{ tok} \times \$0.15/\text{MTok}$	\$0.008
Evaluación — input (con cache)	$100 \times 3,500 \times 85\% \text{ cache} = 297,500 \text{ tok} \times \$0.075/\text{MTok}$	\$0.022
Evaluación — output	$100 \times 200 = 20,000 \text{ tok} \times \$0.60/\text{MTok}$	\$0.012
Triage — input	$10 \times 600 = 6,000 \text{ tok} \times \$0.10/\text{MTok}$	\$0.001
Triage — output	$10 \times 150 = 1,500 \text{ tok} \times \$0.40/\text{MTok}$	\$0.001
TOTAL MENSUAL	100 candidatos + 10 errores	\$0.044
TOTAL ANUAL	$\times 12 \text{ meses}$	\$0.53

Costo real: menos de \$0.05 por mes (menos de 5 centavos de dólar). A este volumen, el costo de IA es despreciable comparado con el costo operativo que reemplaza.

5. Comparativa: ¿Qué Pasaría con Otros Modelos?

Para demostrar el impacto de la elección del modelo, simulamos el mismo escenario (100 candidatos/mes) con modelos alternativos:

Escenario	Modelo Evaluación	Modelo Triage	Costo Mensual	vs Elegido
A: Elegido (óptimo)	GPT-4o mini	GPT-4.1 Nano	\$0.044	— (baseline)
B: Todo con modelo medio	GPT-4.1 Mini	GPT-4.1 Mini	\$0.19	4.3x más caro
C: Todo con modelo potente	GPT-5.4 Mini	GPT-5.4 Mini	\$0.55	12.5x más caro
D: Modelo flagship	GPT-5.4	GPT-5.4 Mini	\$3.15	71.6x más caro
E: Escenario sin optimizar	GPT-5.4 (sin cache)	GPT-5.4 (sin cache)	\$4.78	108.6x más caro

La diferencia entre el escenario E (modelo premium sin optimizaciones) y el escenario A (modelo adecuado + caching) es de más de 100x. La elección del modelo correcto por tarea es la palanca de ahorro más importante, seguida por el prompt caching.

6. Proyección a Escala y Batch API

6.1 Escenario de volumen: 1,000 candidatos/mes

Si la organización escala a 1,000 candidatos mensuales (ej: campaña de reclutamiento masivo, múltiples posiciones simultáneas), los costos escalan linealmente pero la Batch API se convierte en una herramienta de ahorro relevante:

Modo	Modelo	Costo Mensual	Ahorro vs Estándar
API estándar (real-time)	GPT-4o mini	\$0.44	— (baseline)
Batch API (~50%)	GPT-4o mini	\$0.22	50% (\$0.22/mes)
Batch + Cache (compuesto)	GPT-4o mini	\$0.13	70% (\$0.31/mes)

6.2 ¿Cuándo conviene Batch API?

La Batch API de OpenAI ofrece un descuento fijo del 50% en input y output a cambio de una ventana de entrega de 24 horas (en la práctica, 2-8 horas). Es ideal para:

Screening masivo: Procesar todas las postulaciones recibidas durante el día en un batch nocturno. Los candidatos no esperan respuesta inmediata del formulario, por lo que la latencia de 2-8 horas es aceptable.

Re-evaluación periódica: Si cambian las job descriptions, re-evaluar todos los candidatos en Pending Evaluation contra los nuevos perfiles en un batch.

Triage retroactivo: Re-clasificar errores históricos después de actualizar el prompt del agente de triage.

6.3 ¿Cuándo NO conviene Batch API?

Flujo real-time con HITL: Si el proceso requiere que RRHH reciba la solicitud de aprobación minutos después de la postulación, la latencia de batch (2-8h) rompe la expectativa. En el workflow actual, el formulario → evaluación → email a RRHH es un flujo continuo y no se beneficia de batch.

6.4 Implementación técnica del Batch

n8n no tiene un nodo nativo de Batch API, pero se puede implementar con:

Opción A: Nodo Schedule Trigger que dispara un workflow auxiliar cada noche, recopila postulaciones del día desde Airtable (Status = 'Pending Evaluation'), arma el JSONL y llama a la Batch API vía HTTP Request.

Opción B: Mantener el flujo real-time actual (formulario → evaluación inmediata) y reservar batch solo para re-evaluaciones masivas ad-hoc.

7. Estrategias de Optimización Aplicadas

Estrategia	Dónde se aplica	Ahorro estimado	Implementación
Modelo adecuado por tarea	Todo el workflow	70-100x vs modelo premium	Ya implementado: GPT-4o mini para evaluación, GPT-4.1 Nano para triage
Prompt Caching (automático)	Evaluación de candidatos	~40% en tokens de input	Ya implementado: system prompt estable (800+ tokens) se cachea automáticamente en OpenAI
Anonimización pre-IA	Antes del agente evaluador	~15% menos tokens de input	Ya implementado: el CV anonimizado es más corto que el original (placeholders vs datos reales)
Structured Output (JSON schema)	Ambos agentes	Elimina reintentos por formato inválido	Ya implementado: output parser de LangChain garantiza formato JSON válido
Batch API	Re-evaluaciones masivas	50% adicional	No implementado: reservado para escenario de escala (1000+ cand/mes)
Prompt engineering (concisión)	System prompts	~10-20% menos tokens	Ya implementado: prompts concisos con instrucciones explícitas de límite de output (4 oraciones)

8. Análisis de ROI: Costo IA vs Costo Operativo

El valor de la automatización no está en el costo de la API (que es despreciable a este volumen) sino en el costo operativo que reemplaza:

Métrica	Sin automatización	Con automatización	Ahorro
Tiempo de RRHH por candidato	20-30 min (lectura CV + decisión)	2-3 min (revisar score + aprobar/rechazar)	85-90%
Horas RRHH/mes (100 cand.)	33-50 horas	3-5 horas	28-45 horas
Costo RRHH/mes (a \$15/hora)	\$500-750	\$50-75	\$450-675
Costo IA/mes	—	\$0.05	—
Time-to-first-response	1-3 días hábiles	< 1 hora	95%+ reducción
Errores de clasificación	Variable (fatiga, sesgo)	Consistente (mismo criterio siempre)	Reducción de sesgo
Trazabilidad	Parcial (emails, notas)	Total (Airtable log + error triage)	100% auditable

ROI mensual estimado: El ahorro en horas de RRHH (\$450-675/mes) dividido por el costo de IA (\$0.05/mes) da un ROI de 9,000x a 13,500x. Incluso sumando el costo de infraestructura de n8n Cloud (\$20-50/mes) y Airtable Pro (\$20/mes), el ROI supera las 5x.

9. Árbol de Decisión para Selección de Modelo

Guía rápida para elegir modelo en futuros agentes del ecosistema:

¿La tarea requiere razonamiento complejo o comparación densa de textos largos?

SÍ → ¿El volumen es > 500 ejecuciones/mes?

SÍ → GPT-4o mini + Batch API (máximo ahorro con calidad suficiente)

NO → GPT-4o mini estándar (costo despreciable, no vale complicar con batch)

NO → ¿La tarea es clasificación, extracción o formato?

SÍ → GPT-4.1 Nano (el más barato con structured output)

NO → ¿Requiere contexto largo (>50K tokens)?

SÍ → GPT-5.6 Luna (\$0.20/MTok, 1.05M contexto)

NO → GPT-4o mini (default seguro)

Regla general: empezar siempre con el modelo más barato que soporte las capacidades requeridas (structured output, tool use, contexto suficiente). Subir de modelo solo si la calidad del output es insuficiente en testing, nunca por precaución.

10. Conclusiones

1. El costo de IA generativa para un proceso de screening de 100 candidatos/mes es inferior a \$0.05/mes con la selección adecuada de modelos. Es un costo operativo prácticamente nulo.
2. La elección de GPT-4o mini para evaluación y GPT-4.1 Nano para triage produce un ahorro de 70-100x respecto a usar un modelo flagship para ambas tareas, sin pérdida de calidad funcional.
3. El prompt caching automático de OpenAI aporta un 40% de ahorro adicional en tokens de input sin ningún cambio de código, gracias a que el system prompt es estable entre ejecuciones.
4. La Batch API (50% descuento) es una herramienta de escala: no tiene sentido implementarla a 100 candidatos/mes, pero sí a partir de 1,000+ candidatos/mes o para re-evaluaciones masivas.
5. El verdadero ROI no está en el costo de la API sino en las 28-45 horas/mes de trabajo manual de RRHH que se liberan, con un time-to-response que pasa de días a minutos.